

# Tehnici de Optimizare


## Laborator 4

– Probleme de optimizare cu restricții –

### 1 Introducere

**Problema de clasificare SVM:** Fie seturile de "obiecte"  $X^+ = \{x_1^+, x_2^+, \dots, x_m^+\}$ ,  $X^- = \{x_1^-, x_2^-, \dots, x_m^-\}$ . Determinați hiperplanul  $H(w, b)$  de *margină maximă* care separă (distinge) cele două seturi.

$$\begin{aligned} w^T x_i^+ + b &> 0 \quad i = 1, \dots, m \\ w^T x_i^- + b &< 0 \quad i = 1, \dots, m. \end{aligned}$$



În cazul separabil, printr-o simplă schimbare de variabilă, problema se reduce la găsirea perechii  $(\hat{w}, \hat{b})$  astfel încât:


$$y_i(\hat{w}^T x_i + \hat{b}) \geq 1 \quad \forall x_i \in X^+ \cup X^-,$$

unde  $y_i = +1$  dacă  $x_i \in X^+$  sau  $y_i = -1$  dacă  $x_i \in X^-$ .

**Observație:** Pentru simplitate, vom folosi mai departe, în loc de  $(\hat{w}, \hat{b})$ , notațiile originale  $(w, b)$ .

Distingem hiperplanele auxiliare de separare  $H(w, 1 - b)$  și  $H(w, -1 - b)$  (figurate cu linie punctată): Pentru forma analitică a marginii (distanța pâna la  $H(w, \pm 1 - b)$ ) observăm:

$$\begin{aligned} x_a &= x'_a + r \frac{w}{\|w\|} \Rightarrow w^T x_a + b = 1 \\ &\Rightarrow w^T (x'_a + r \frac{w}{\|w\|}) + b = 1 \\ &\Rightarrow r = 1/\|w\|. \end{aligned}$$




De aceea, asigurarea marginii maxime de separare se atinge prin rezolvarea problemei:

$$\begin{aligned} \max_{w,b} \quad & \frac{1}{\|w\|} \\ \text{s.l.} \quad & y_i(w^T x_i + b) \geq 1 \quad \forall i = 1, \dots, m \end{aligned}$$

Maximizarea  $\frac{1}{\|w\|}$  este echivalentă cu minimizarea  $\|w\|$  sau  $\|w\|^2$ , de aceea rescriem:

$$\begin{aligned} (\text{SVM separabil}): \quad & \min_{w,b} \|w\|^2 \\ \text{s.l.} \quad & y_i(w^T x_i + b) \geq 1 \quad \forall i = 1, \dots, m. \end{aligned}$$


În cele mai realiste situații (e.g. clasificarea de documente) ipoteza de separabilitate nu este verosimilă, de aceea, se urmărește clasificarea cu "eroare" minimă.



Modelăm eroarea printr-un set de variabile virtuale  $\xi_i = 1 - y_i(w^T x_i - b)$  nenegative. Natural, ne dorim la optim ca valoarea variabilelor de eroare sa fie cât mai mici posibil.

În problema de **SVM neseparabil** identificăm  $\xi_i = 1 - y_i(w^T x_i - b) \geq 0$  și penalizăm în cost valoarea cumulată a variabilelor de eroare  $\sum_i \xi_i$ :

$$\begin{aligned} (\text{SVM neseparabil}): \quad & \min_{w,b,\xi} \|w\|^2 + \rho \sum_i \xi_i \\ \text{s.l.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i \quad \forall i = 1, \dots, m \\ & \xi \geq 0. \end{aligned}$$



Numărul mare de constrângeri face problema **SVM neseparabil** greu de abordat în forma primală. Deoarece intervin doar constrângeri liniare de inegalitate, utilizăm argumentul dualității pentru a simplifica problema.

$$\mathcal{L}(w, b, \xi, \lambda, \gamma) = \frac{1}{2} \|w\|^2 + \rho \sum_i \xi_i - \sum_{i=1}^m \lambda_i [y_i (w^T x_i + b) - 1 + \xi_i] - \sum_{i=1}^m \gamma_i \xi_i.$$

Condițiile Kuhn-Tucker de optimalitate primal-duală:

$$\nabla_w \mathcal{L}(w, b, \xi, \lambda, \gamma) = w - \sum_{i=1}^m \lambda_i y_i x_i = 0$$

$$\nabla_b \mathcal{L}(w, b, \xi, \lambda, \gamma) = - \sum_{i=1}^m \lambda_i y_i = 0$$

$$\nabla_{\xi_i} \mathcal{L}(w, b, \xi, \lambda, \gamma) = \rho - \lambda_i - \gamma_i.$$

Din prima relație observăm la optim:

$$w^* = \sum_{i=1}^m \lambda_i^* y_i x_i. \quad (1)$$

Datele  $x_i$  pentru care  $\lambda_i^* = 0$  nu contribuie la soluția problemei **SVM neseparabil**, iar cele pentru care  $\lambda_i^* > 0$  se numesc **vectori suport** și satisfac  $w^T x^i + b = y_i$  (se poziționează pe hiperplanele auxiliare). După eliminarea variabilelor primale, obținem problema duală pentru **SVM neseparabil**:

$$\begin{aligned} (\text{SVM dual}): \quad & \max_{\lambda} \quad -\frac{1}{2} \lambda^T Q^T Q \lambda + e^T \lambda \\ & \text{s.l. } y^T \lambda = 0, \quad 0 \leq \lambda_i \leq \rho. \end{aligned}$$

unde  $Q = [y_1 x^1 \quad y_2 x^2 \quad \dots \quad y_m x^m]$ . După rezolvarea problemei **SVM dual**, soluție primală se determină pe baza (1) și, în plus,  $b = y_i - w^T x^i$  pentru orice index  $i$  corespunzător vectorilor suport.

## 2 Probleme propuse

1. Generați  $m$  date aleatoare separabile în  $\mathbb{R}^n$ . Determinați hiperplanul de margine maximă rezolvând **SVM separabil**, folosind CVXPY. Testați optimalitatea soluției.
2. Generați  $m$  date aleatoare (ne)separabile în  $\mathbb{R}^n$ .

- a. Reformulați problema SVM `dual` pentru a elimina constrângerea de egalitate, adăugând în obiectiv funcția de penalitate corespunzătoare.
- b. Implementați Metoda Gradientului Dual (MGD) pentru rezolvarea problemei duale modificate de la punctul *a*.
- c. Calculați soluția primală  $(w^*, b^*)$  pornind de la multiplicatorii Lagrange furnizați de MGD de la punctul *b*.

## 2.1 Ghid Python

Importare pachete necesare:

```
import numpy as np
from numpy import linalg
from numpy.linalg import norm
import numpy.random as random
import matplotlib.pyplot as plt
```

Exemplu generare vector aleator:

```
s = random.rand(n)
```

Exemplu generare intreg aleator între 0 și *m*:

```
i = random.randint(m, size = 1)
```